Postępy pracy

Postępy pracy (stan na 2026-10-19)

Temat: dynamiczny i semantyczny routing zapytań według złożoności zadania (DeepFellow Infra, `RouterService`). Plan: `../../koncepcja.md`. Pełny przebieg i decyzje: `DZIENNIK.md` (wpisy 1–43). Zbiór **test jest zamknięty** (nie użyty do niczego).

1. Co zrobione

Etap	Wynik
Zbiór pytań	4313 pytań (angielski, jedna tura): Arena 1726, WildChat 999, pytania Gemini 450, GSM8K 300, MMLU 300, TriviaQA 296, HumanEval 164, MT-Bench 78
Podział	train 2151 / cal 859 / test 1294 (zamknięty); prawie-duplikaty (podobieństwo embeddingów ≥ 0,95) zawsze w jednym zbiorze; MMLU, MT-Bench i 150 pytań GSM8K tylko w teście (poza dziedziną)
Pomiar	każde pytanie: mały model (`qwen3:8b`) 3 odpowiedzi, duży (`Qwen3.8-27B-FP8`) 1; łącznie 17252 odpowiedzi; myślenie wyłączone, limit 2048 tokenów
Ocena	pytania ze znaną odpowiedzią (1060): automatycznie (liczba, litera, alias, testy kodu); pytania otwarte (3244): sędzia Gemini 3.8 Flash, skala 1–5, odpowiedzi w losowej kolejności, bez nazw modeli
Etykieta	Δ = Q_duży − średnia(Q_mały), po normalizacji do 0–1; COMPLEX gdy Δ > 0,25; 4304 pytań z etykietą
Router (offline)	warstwa 1 (reguły), warstwa 2 (kNN na embeddingach `nomic-embed-text`), punkty odniesienia, bootstrap, walidacja krzyżowa po grupach

2. Zmierzone etykiety

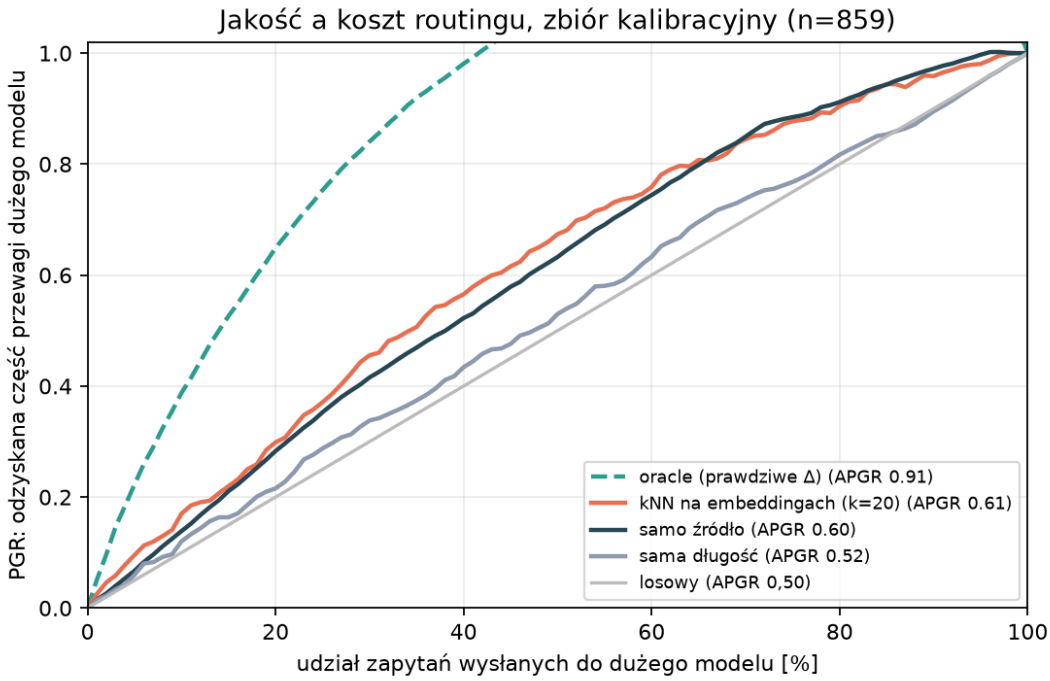
- **35,4%** pytań to COMPLEX (duży wyraźnie lepszy), reszta SIMPLE. Wrażliwość na próg: 51,5% (Δ > 0,15) – 27,6% (Δ > 0,35).
- Zależy od rodzaju pytań: WildChat 48%, Arena 45%, MMLU 28%, TriviaQA 20%, HumanEval 18%, pytania od Gemini 16%, GSM8K 4%.
- Poprawność (pytania ze znaną odpowiedzią), duży / mały: GSM8K 97% / 97%, HumanEval 94% / 83%, MMLU 81% / 66%, TriviaQA 60% / 47%.

- Szum: dla pytań otwartych etykieta z jednej próbki małego zgadza się we wszystkich trzech próbkach w 74% pytań (ze znaną odpowiedzią 92%); stąd trzy próbki.
- Brak silnego obciążenia sędziego długością odpowiedzi (korelacja Δ z różnicą długości 0,06). Ucięte odpowiedzi (duży 6,7%, mały 1,7%) zmieniają odsetek COMPLEX najwyżej o ok. 2 punkty procentowe.
- Szum sędziego: ten sam sędzia (Gemini 3.8 Flash) przy innej kolejności odpowiedzi daje tę samą klasę w 90% pytań; drugi sędzia (Gemini 3.1 Pro, 99 pytań) zgadza się z Flash co do klasy w 79% (Pro daje mniej COMPLEX: 36% vs 43%). Ocena człowieka (100 odpowiedzi): zob. sekcja „Ocena człowieka" poniżej.
- Zmierzone Δ słabo zgadza się z głosowaniami ludzi w Arenie (AUROC 0,55; inne modele, inna epoka), co potwierdza, że etykiety trzeba mierzyć dla konkretnej pary modeli.
- Wg kategorii: najwięcej COMPLEX w wiedzy STEM (57%), najmniej w matematyce (13%; mały model dobrze liczy), więc „trudność" w sensie przewagi dużego modelu nie pokrywa się z intuicją.
- 9 pytań zablokował Gemini (`PROHIBITED_CONTENT`); wyłączone.

3. Wyniki routera (walidacja krzyżowa po grupach, train+cal, 3010 pytań, Δ > 0,25)

Metoda	AUROC	APGR
losowy	0,50	0,50
sama długość	0,525	0,523
samo źródło	0,631	0,582
warstwa 1 (reguły)	0,577	0,543
warstwa 2 (kNN, embeddingi)	**0,682**	**0,605**
warstwa 1 + 2	0,676	0,603
oracle (prawdziwe Δ)	1,00	0,91

Wykres (cal): `figures/pgr_cal.png`



{width=85%} .

- kNN bije „samo źródło” istotnie, ale niewiele: APGR +0,023 [+0,009; +0,038], AUROC +0,051 [+0,028; +0,074]. Bije długość wyraźnie (APGR +0,082).
- Warstwa 1 (reguły) nie poprawia wyniku ponad warstwę 2 (różnica APGR −0,002 [−0,013; +0,009]).
- Wnioski te same dla progów Δ 0,15 i 0,35.
- Pułap wynikający z szumu etykiet (szacunek, zawyżony): AUROC ok. 0,9, więc jest miejsce na poprawę (warstwa 3, lepsze cechy).

Co to znaczy w praktyce (kNN, poza próbką; jakość 0–1: zawsze mały 0,625, zawsze duży 0,846)

Próg wyniku	Do dużego	Jakość	Utrata względem „zawsze duży”
0,20	76,5%	0,819	0,027
0,30	54,3%	0,777	0,069
0,40	35,1%	0,734	0,112
0,50	20,1%	0,694	0,152

Czyli np. oszczędność ok. 46% wywołań dużego modelu przy utracie jakości ok. 8% względnej (0,846 → 0,777). Jest to efekt umiarkowany: router daje realny, ale niewielki zysk ponad prosty punkt odniesienia.

Błędy routera i wybór embeddera

- Błąd krytyczny ($\Delta > 0{,}5$ skierowane do małego) przy progu 0,3: 30% takich pytań wobec 46% losowo; router wychwytuje je dla pytań otwartych (Arena, WildChat), ale prawie nie wychwytuje dla TriviaQA (81% pominięte) i HumanEval (84%): czy mały model zna fakt lub poradzi sobie z funkcją, nie wynika z treści pytania w embeddingu. Błąd kosztowy (mały wystarczył, a poszło do dużego): 35% wobec 54% losowo.

- Embeddery (kNN, CV): nomic 0,689 AUROC, qwen3-embedding 0,709 (APGR bez istotnej różnicy), bge-m3 0,685, mxbai 0,679; qwen3 jest 3× wolniejszy (p50 52 ms wobec 17,6 ms), więc zostaje nomic. Żaden z 9 klasyfikatorów nie bije kNN: sufit embeddingów ok. 0,68–0,71 AUROC.

4. Odporność, opóźnienie, implementacja

- Implementacja: `RouterService` w DeepFellow Infra v0.34.0 (nowy `server/router/` i `server/services/router_service.py`), opcje usługi w JSON, nagłówki `X-Router-*`, fallback na duży model; 46 nowych testów (w tym 6 integracyjnych na prawdziwym `EndpointRegistry` i test zdrowia modelu DF), cały zestaw DF (5146 testów) zielony, `just check` bez błędów, pokrycie 100%. Dodana zależność `numpy`. Sprawdzony end-to-end na odizolowanej instancji DF (prawdziwe HTTP, `ollama-external` z nomic jako embedder, modele Gemini jako „mały" i „duży"): routing wg wyniku kNN, nagłówki `X-Router-*` także przy strumieniowaniu, fallback na duży model, gdy mały zwraca błąd (404 dla wycofanego modelu), odtworzenie konfiguracji po restarcie. Jeszcze nie uruchomiony z Qwenem 8B/27B: instrukcja w `ROUTER_URUCHOMIENIE.md`.

- Odporność (299 pytań z cal, wersje z literówkami, parafrazami, synonimami): decyzja routera zmienia się dla 6–10% pytań przy 30%/50% do dużego (przy losowych wynikach byłoby 42–48%); korelacja wyników 0,92–0,95.

- Opóźnienie L1+L2 (natywna Ollama, M1 8 GB, bez DF): p50 20,6 ms, p90 65,5 ms. Cel < 50 ms spełniony dla mediany, nie dla p90 (zależy od długości pytania i obciążenia komputera).

5. Ograniczenia, które trzeba nazwać

- Duży model ma jedną próbkę na pytanie (jego szum nieoceniony).
- Etykiety pytań otwartych pochodzą od jednego sędziego (Gemini 3.8 Flash); zgodność klasy z innym sędzią (Pro) to tylko 79%, a z oceną człowieka zgodność jest umiarkowana (Spearman 0,59, zob. sekcja „Ocena człowieka").
- TriviaQA: brak licencji w metadanych zbioru; dopasowanie aliasów nie jest wyraźnie zbyt ścisłe (przegląd 30 przypadków), ale tylko próbkowo.
- Jedna para modeli (Qwen3.8-27B-FP8 i qwen3:8b); jeden zbiór; parafrazy do testu odporności wygenerował model Google (mogły nieznacznie zmienić trudność).
- Pomiar opóźnienia nie przez DF i nie na docelowym sprzęcie.

6. Następne kroki

1. Warstwa 3 (mały model zero-shot): test go/no-go (wymaga dostępu do modeli i logprobs w DF).
2. Zgoda promotora na cele liczbowe (`CELE_PRZED_TESTEM.md`) i dopiero potem otwarcie testu.
3. Wybór sędziego/sędziów dla etykiet końcowych (ocena człowieka wykonana, zob. niżej; sędzia jest surowszy i tylko umiarkowanie zgodny z człowiekiem).

4. `RouterService` w DeepFellow Infra v0.34.0 (opcje JSON, in-process przez `EndpointRegistry`), pomiar opóźnienia przez DF.
5. Ewaluacja końcowa na teście (jednokrotne otwarcie), w tym ruch poza dziedziną i błąd krytyczny.

Uzupełnienie: krzywa uczenia

Wyniki routera wypłaszczają się z liczbą pytań w indeksie: AUROC 0,628 (240 pytań), 0,653 (602), 0,673 (1204), 0,675 (1806), 0,682 (2408); podwojenie danych powyżej ok. 1200 pytań daje tylko ok. +0,01 AUROC. Dalsza poprawa wymagałaby innego sygnału (np. warstwy 3) lub bardziej zróżnicowanych danych, nie większej liczby podobnych pytań.

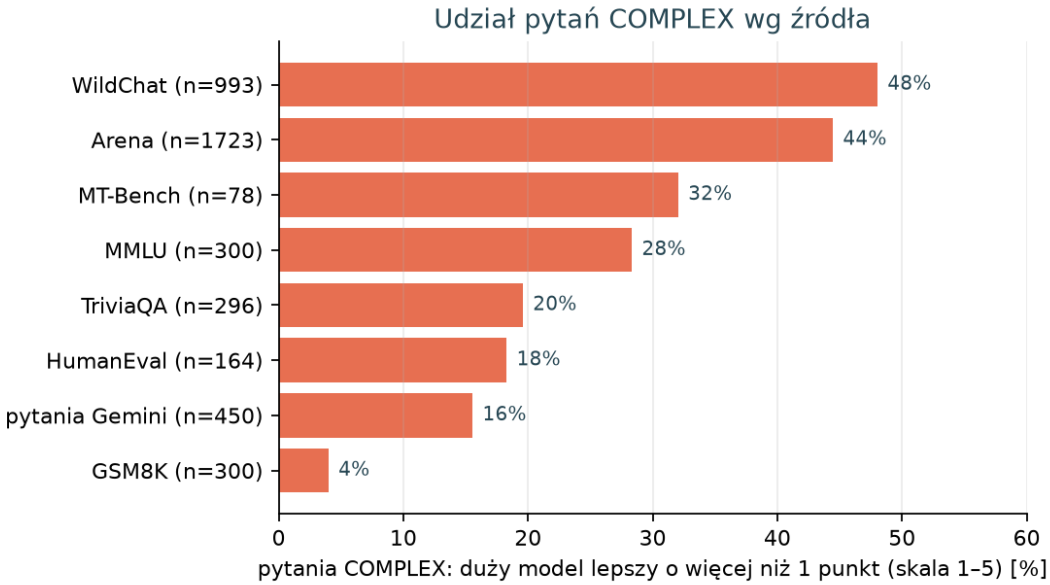
Ocena człowieka: 100 odpowiedzi (warstwowa próbka, po 20 na każdą ocenę sędziego 1–5)

Autor ocenił odpowiedzi w skali 1–5, nie wiedząc, który model odpowiadał (narzędzie `eval/human_rate.py`). Oceny są ostateczne po przejrzeniu: autor omawiał odpowiedzi z asystentem, przyjął jego propozycje dla 8 pozycji, których sam nie umiał ocenić (obcy język, rola, kod), i poprawił 6 ocen tam, gdzie odpowiedź ma sprawdzalny błąd. Porównanie z sędzią Gemini 3.8 Flash (n = 100):

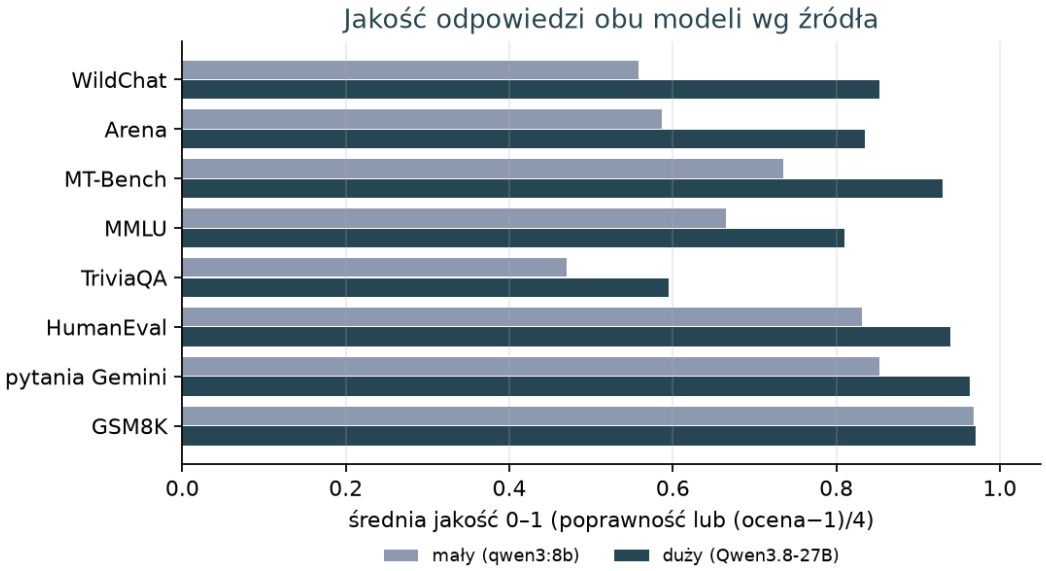
Miara	**Wynik**
Identyczna ocena	43,0%
Różnica najwyżej o 1 punkt	77,0%
Korelacja Spearmana	0,592
Zgodność „zła odpowiedź” (ocena ≤ 2 vs > 2)	76,0%
Średnia: człowiek / sędzia	3,40 / 3,00

- Kierunek zgodny, ale **sędzia jest surowszy** o ok. 0,4 punktu.
- Człowiek też nie jest wyrocznią (nie weryfikuje faktów w każdym pytaniu), próbka jest mała (tylko 15 odpowiedzi dużego modelu), więc wniosek jest ostrożny: zgodność człowiek–sędzia jest umiarkowana. Stałe przesunięcie skali sędziego znosi się w różnicy Δ; szum rozbieżności nie. Dla pytań ze znaną odpowiedzią (ocena automatyczna) nie dotyczy.

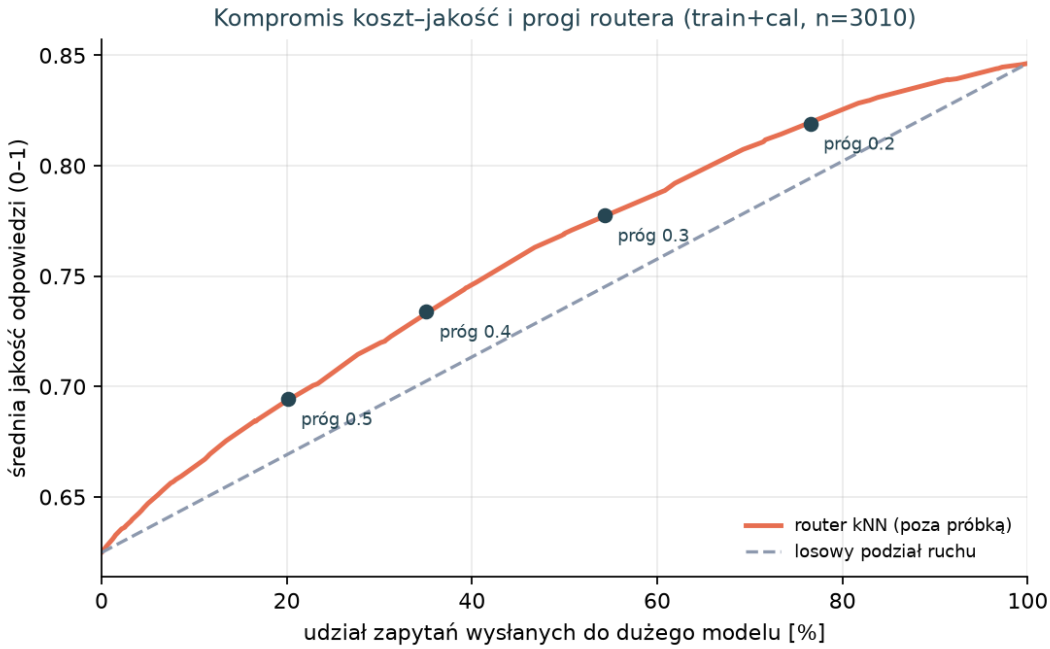
Wykresy



{width=85%}



{width=85%}


Kompromis koszt–jakość i progi routera (train+cal, n=3010)
średnia jakość odpowiedzi (0–1)
0.85
0.80
0.75
0.70
0.65
próg 0.2
próg 0.3
próg 0.4
próg 0.5
router kNN (poza próbką)
losowy podział ruchu
0
20
40
60
80
100
udział zapytań wysłanych do dużego modelu [%]

{width=85%}